

# Le calcul est devenu une ressource économique

Pendant longtemps : le calcul était principalement une ressource utile à des fins de recherche

Aujourd'hui : le calcul est aussi une ressource économique et stratégique.


Au travers de ce document nous nous poserons beaucoup de questions (parfois sans réponse) autour de cette nouvelle denrée

- **Le secteur est-il pérenne ?**
- **Combien coûte réellement une unité de calcul ?**
- **Va-t-on atteindre une limite ?**
- **Qu'elle est la géopolitique derrière les supercalculateurs ?**
- **Etc...**



On parle beaucoup de bulle économique lorsque se penche sur le cas de l'environnement de marché de l'IA, des GPU et des serveurs.


Mais est-ce pour autant le cas ? Nous verrons dans ce document que ce secteur économique peut en effet être sensible aux perturbations, mais pas pour les raisons que l'on croit.




# D'où vient la demande ?

Le boum de l'IA est en grande partie responsable de du développement du marché des GPU

Plus précisément, le développement de modèles d'IA "utiles" nécessitaient de la puissance de calcul qui n'a été atteint que lors de la dernière décennie 10's




# Taille des jeux d'entraînement des IA au cours du temps




# Nombre de paramètres de modèles IA au cours du temps

Number of parameters (plotted on a logarithmic axis)



# Puissance de calcul alloué à l'entraînement des IA au cours du temps

Training computation (petaFLOP; plotted on a logarithmic axis)




$$\ln(X) = e(\ln(76.53/0.42)/18)$$

On a vu sur le schéma précédent que la puissance de calcul alloué à l'IA est de x4 tout les ans, les machines du TOP500 on du mal a suivre la cadence (environ x2 tout les ans).



## Évolution de la puissance de calcul des supercalculateurs du TOP500



# Quelques ordres de grandeurs

Les GPU haut de gamme pour les calculateurs sont différent des GPU grand publique pour le gaming



On se situe vers **40,000\$ la carte** (B200 = **4,500 TFLOPS** sur des FP8)

Un serveur GPU compte plusieurs GPU, la facteur peut vite grimper. Pour les cluster de calcule, on monte à la centaine voire millier de carte, donc en prenant en compte aussi les serveurs + réseau + stockage + intégration, on monte facilement à **la centaine de millions de \$**.



Un GPU dernière génération consomme entre **500 et 1000 W !**

Rappel : 1 kWh = 0,2€ en france



L'un des facteurs important est différence entre prix d'achat et coût total de possession. On estime qu'un **GPU est rentable à 1,5x son prix d'achat** sur 5 ans.

Par exemple, la location d'une carte B200 coûte entre 3 et 6\$ de l'heure.

# la chaîne de valeur d'un GPU



Fabriquante de GPU

Sous-traitant

Fabricants de  
mémoire

packaging

Fonderies

Fabricants de serveurs

Équipementiers réseau

Fournisseurs cloud

Développeurs de  
modèles

Utilisateurs finaux

**Qui capte la valeur ?**

# Les terres rares



Les GPU modernes intègrent plusieurs éléments de terres rares et de métaux critiques pour optimiser la gestion thermique, l'alimentation et la miniaturisation des composants.

Bien que le cœur d'un processeur soit principalement en silicium et en cuivre, les puces graphiques avancées (notamment pour l'intelligence artificielle) ont besoin de substances spécifiques :



- Le gadolinium : Il est utilisé pour améliorer la gestion de la température des puces.
- Le néodyme : On le trouve dans certains condensateurs et composants magnétiques associés.
- D'autres métaux critiques (cérium, yttrium, gallium) : Ils entrent dans la fabrication des semi-conducteurs avancés.

# Les terres rares



Les terres rares se situent tout en haut de la chaîne de production des GPU et autres composant électronique  
La Chine est aujourd'hui le principal exportateur de cette matière première.

# ASML, ou le monopole de la lithographie

# ASML

Pour fabriquer les puces les plus avancées, il faut imprimer des motifs extrêmement petits sur le silicium. Pour ce faire, il faut des lumières EUV (Extreme Ultraviolet) assez puissante, les guider et les focaliser, tout cela sur des waffers positionner avec une précision extrême.



Ensuite, une entreprise comme TSMC (aussi un quasi monopole) achète les machines de ASML pour fabriquer leurs puces.

C'est ensuite que NVIDIA achète à TSMC.


# le chip binning

On fabrique beaucoup de puces selon le même design, mais le processus de lithographie n'est pas parfait et peut amener à des erreurs. En fonction de leurs performances et de leurs défauts, on les classe dans différentes catégories commerciales.

Quand on fabrique des milliards de transistors sur un wafer, toutes les puces ne sont pas parfaitement identiques. Certaines ont :

- aucun défaut significatif
- quelques unités de calcul défectueuses
- une fréquence maximale plus basse
- des défauts qui empêchent certaines fonctions.

Donc, au lieu de jeter toutes les puces qui ne correspondent pas au modèle idéal, le fabricant peut récupérer une grande partie de la production, et créer différentes gammes de puce en fonction des résultats de chacune.



# Le logiciel comme verrouillage économique



CUDA signifie **C**ompute **U**nified **D**evice **A**rchitecture.

C'est la plateforme de NVIDIA qui permet à un programme d'effectuer une partie des ses calculs sur GPU.

Aujourd'hui, AMD propose ROCm, qui est précisément une alternative à CUDA. Intel a également son propre écosystème.

AU début des années 2000, les GPU étaient surtout vus comme des accélérateurs graphiques. NVIDIA ont été les premiers à transformé le GPU en plateforme de calcul programmable, utilisable par le monde scientifique via CUDA, il y a donc un «Network effect» comme une boule de neige.

Ainsi, quand le deep learning est arrivé en force, CUDA c'était déjà imposé naturellement, et donc les hardware NVIDIA avec.

Aujourd'hui, migrer de GPU NVIDIA à GPU AMD demande plus que changer les GPU, cela demande des connaissances !

